



zvec 知识库插件 设计系统

面向 DeepSeek Harness 的本地知识库插件设计系统。基于 zvec 进程内向量数据库构建，覆盖知识库创建、文档上传、索引构建、知识检索工具与 RAG 问答的完整链路，为插件 UI 提供统一的视觉语言、设计令牌与组件规范。

+ 创建知识库

⬆ 文档上传

≡ 索引构建

🔍 知识检索工具

💬 RAG 问答

DESIGN TOKENS

51 项设计令牌

COMPONENTS

24 个基础组件

MODULES

8 个知识库模块

THEMES

浅色 / 深色

01 色彩系统

02 字体与尺度

03 基础组件

04 业务组件

05 应用界面


色彩系统

以靛蓝 Indigo 为唯一品牌主色，承担主操作、选中态与焦点态；青绿 Teal 只在「就绪 / 已完成」时出现，琥珀 Amber 表示「构建中」，玫红 Rose 表示「失败」。中性色承担界面骨架，通过边框与层级差而非重投影建立深度。


22 COLOR TOKENS · LIGHT + DARK

品牌主色阶 · Indigo

brand-500 #4F5BD5 为基准色。浅阶用于选中背景与信息底纹，深阶用于悬停、按下与深色主题承载。




深色主题映射 · Dark Mode



中性色阶 · Neutral

neutral-50 为应用底色，neutral-0 为卡片承载面；分割线只用 neutral-200，弱化装饰性描边。文字三级：primary / secondary / tertiary。



语义状态色 · Semantic

知识库与文档的生命周期状态。每个状态固定搭配「实色点 + 底纹」组合，禁止仅靠颜色区分。



检索置信度色阶 · Match Score

对 zvec 距离做归一化后的相似度分数。用于结果排序与人工可信度判断，禁止直接暴露原始距离值。



结果排序示例



字体、间距与层级

界面字体统一使用 Noto Sans SC，技术标识、向量维度、文件名与分数使用 JetBrains Mono。间距以 4px 为基础单位，绝大多数场景只用 8 / 12 / 16 / 24 / 32。层级优先用边框与底色差表达，阴影仅用于浮层。

字体家族 · Typeface

双字体策略：中文与界面文案用 Noto Sans SC，所有机器生成的标识与数值用 JetBrains Mono 并启用等宽数字，保证列表纵向对齐。

界面字体 · UI Sans

知识库检索与向量嵌入

Regular 400 · 正文、表单与列表内容

Medium 500 · 按钮、标签与导航项

SemiBold 600 · 卡片标题与关键数值

Bold 700 · 页面主标题与空状态

技术字体 · Mono

kb_prod_2f8a

Regular 400 · 文件名、路径、集合标识

Medium 500 · 相似度分数与时间戳

tabular-nums on · 0.92 / 1024d / v_fp32

字号阶梯 · Type Scale

共 8 级。页面只允许出现一个 display 级标题；卡片内标题不超过 h3，保证层级可读。

TOKEN	字号 / 行高 · 用途	SAMPLE
display	32 / 42 · 页面主标题	知识库总览
h2	24 / 34 · 区块标题	文档与索引构建
h3	20 / 30 · 卡片标题	检索结果
title	16 / 24 · 列表项标题	zvec-architecture.md
body	14 / 22 · 正文与表单	支持 Markdown / PDF / DOCX / TXT 等格式
body-sm	13 / 20 · 辅助说明	嵌入模型 text-embedding-v4 · 1024 维 · 余弦距离
caption	12 / 18 · 标签与元信息	构建于 2026-09-14 10:28 · 耗时 42s · 128 个分片
mono	11 / 16 · 令牌与技术标识	kb_prod_2f8a · 0.92 · HNSW · match_score

间距 · 圆角 · 层级

4px 网格。层级系统只有三级，通过描边与极轻的投影建立深度，避免多层阴影堆叠。

间距 · Spacing



4 · 8 · 12 · 16 · 20 · 24 · 32 · 40 · 48 · 64

圆角 · Radius



xs 4 控件 · sm 6 标签 · md 8 卡片与输入 · lg 12 弹窗 · xl 16 容器

层级 · Elevation

level-1 · 内嵌卡片 / 输入框

level-2 · 悬浮卡片 / 下拉

level-3 · 弹窗与抽屉

基础组件

组件按「尺寸 × 状态」两个维度穷举，每种组件都必须实现 default / hover / focus / disabled / loading 五态。所有交互控件高度统一为 28 / 34 / 40 三档，保证同一表单内基线对齐。


按钮 • Button

全局每个视图只允许出现一个 primary 主按钮。危险操作必须配合二次确认，不允许直接触发删除。


变体 • Variants



尺寸 • Sizes



状态 • States



表单控件 • Input

标签在控件上方，辅助说明在下方。聚焦态统一使用 1px 主色描边 + 2px 主色浅晕，不使用投影。

输入类 • Text Entry

知识库名称



检索关键词 • 聚焦态



知识库说明



选择类 • Selection

嵌入模型



索引选项



标签、状态与切换控件

状态胶囊必须携带文字，颜色只作辅助；计数徽标超过两位显示 99+；图标按钮必须提供 tooltip 与可访问名称。

状态胶囊 • Status Pill



标签与徽标 • Tag & Badge



图标按钮与分段控件 • Icon & Segmented



分段控件 • Segmented



选项卡 • Tabs



知识库核心模块

由基础组件组合而成的业务模块，覆盖插件的四个关键任务：知识库识别、文档接入、索引构建、检索结果呈现。同一模块在列表页与会话内嵌视图中复用，只改变密度。

8 KNOWLEDGE MODULES

知识库卡片 · Knowledge Base Card

卡片同时承载身份、状态与规模三类信息。状态胶囊固定在右上角，操作只在卡片被选中时出现。



产品技术文档库

kb_prod_2f8a · HNSW · cosine

就绪

文档 128 · 分片 1,024 · 近 7 日命中 3,241 次

更新于 2026-09-14 10:28

重建索引

查看详情

文档接入 · Upload & Document Row

上传区在读屏器中必须可被键盘触达；单文件上传在行内显示进度与取消入口，不做全局遮罩。



拖拽文件到此处，或点击选择文件

支持 Markdown / PDF / DOCX / TXT，单文件不超过 50 MB



index-tuning-guide.pdf

2.4 MB

68%



索引构建 · Build Pipeline

四个阶段必须同时给出「名称 + 状态 + 进度」，禁止只显示无文字的进度条。构建日志默认折叠。



解析文档



切分与嵌入



写入索引 · 进行中



校验与发布

正在向量化 86 / 128 分片 · 预计剩余 12s

67%

[10:28:04] embed batch 86/128 ok · 512 chunks

[10:28:11] hnsw insert 512 vectors · 41ms

检索结果与工具调用 · Retrieval & Tool Call

结果卡片必须可回溯到具体文档与段落；工具调用块在会话中默认折叠为一行摘要，展开显示参数与命中数。

zvec-architecture.md · 第 24 段 · P128-P171

0.92 强相关

HNSW 图在构建阶段通过逐层插入维护邻居关系，efConstruction 决定候选集大小；将其提高到 200 可显著改善高维向量在高召回场景下的检索精度，代价是构建时间增长约 1.6 倍。



dsh_kb_search

5 条命中 · 38ms

query: "HNSW 索引参数" · collection: kb_prod_2f8a · topk: 5

切分策略 · Chunking Strategy

切分决定检索命中粒度：粒度太小丢上下文，太大稀释相关性。参数必须在配置阶段显式确认，并给出分片预览。

切分方式

按标题层级

按段落

固定长度

分片长度

1024 token

重叠长度

128 token

特殊处理



保留代码块



表格按行拆分

分片预览 · 前 2 片

分片 #1 · 458 token · 来源 zvec-architecture.md

HNSW 图在构建阶段通过逐层插入维护邻居关系，efConstruction 决定候选集大小；将其提高可改善高维向量的召回上限。

分片 #2 · 476 token · 重叠 128 token

提高 efConstruction 到 200 后召回率提升约 4.2 个百分点，构建耗时增长约 1.6 倍，需要权衡。

嵌入与索引策略 · Embedding & Index

维度必须与嵌入模型对齐，距离度量必须与向量归一化方式一致。索引类型与量化器决定召回与存储的取舍。

嵌入模型

text-embedding-v4 · 1024 维 · 支持稀疏

向量维度 · 数据类型

1024 · VECTOR_FP32

距离度量

cosine

索引类型

HNSW

IVF

DiskANN

M · 每层邻居数

32

efConstruction · 候选集

200

量化器 · 存储压缩

PQ-INT8 · 存储压缩 4×，召回损失 < 1.5%

混合检索权重 · RRF 融合

稠密向量 semantic

0.70

全文检索 BM25 / n-gram

0.30

预估: 128 文档 → 1,024 分片 · 构建约 42s · 向量存储 412 MB

知识库详情 · 文档与构建

插件的主操作台。左侧承担文档管理（高频、需要扫视），右侧承担构建配置（低频、需要确认），两侧不共享滚动容器。

1440 × 900 · LIGHT

知识库

zvec · local

概览

知识库

文档

检索测试

构建历史

设置

产品技术文档库

知识库 / 产品技术文档库

产品技术文档库

kb_prod_2f8a · HNSW · cosine · text-embedding-v4 · 128 文档 / 1,024 分片

重建索引 上传文档

文档 · 128

索引配置

构建日志

文档列表

Q 筛选文档

文件名	类型	分片	状态
zvec-architecture.md	MD	42	已就绪
index-tuning-guide.pdf	PDF	128	已就绪
embedding-benchmark.docx	DOCX	86	构建中
faq-collection.txt	TXT	24	待构建
api-reference-v3.md	MD	312	已就绪
deployment-runbook.pdf	PDF	96	已就绪
changelog-2026.txt	TXT	18	已就绪

构建配置

切分策略

按语义 · 1024 token

嵌入模型

text-embedding-v4

索引类型

HNSW · cosine

重建全部索引

重建期间检索工具返回上一次快照，不会中断正在进行的会话。

上次构建

完成时间

今天 09:14

处理规模

128 文档 / 1,024 分片

总耗时

42s

本地索引占用

412 MB / 2 GB

检索测试与 RAG 问答

左侧调试检索参数并查看原始命中，右侧把命中结果交给模型生成带引用的回答。两侧共用同一次查询，保证「调参 → 验证」闭环。

1440 × 900 · LIGHT



索引策略配置

切分策略与嵌入策略的完整配置面。左侧调参并实时预览分片效果，右侧对齐嵌入模型、索引与量化参数，底部给出规模与耗时预估后才允许提交。

1440 × 900 · LIGHT

知识库

zvec · local

概览

知识库

文档

检索测试

构建历史

设置

索引策略配置

切分策略 · Chunking

推荐：按标题层级 · 1024 token

切分方式

按标题层级

按段落

固定长度

分片长度

重叠长度

最小分片（低于则丢弃）

1024 token

128 token

64 token

特殊处理

☒ 按标题层级切分时保留代码块完整

☐ 表格按行拆分

分片预览

1 / 128 <

分片 #1 · 458 token · zvec-architecture.md · 第 24 段

HNSW 图在构建阶段通过逐层插入维护邻居关系，efConstruction 决定候选集大小；将其提高可改善高维向量的召回上限。

分片 #2 · 476 token · 与上一片重叠 128 token

将 efConstruction 提高到 200 后召回率提升约 4.2 个百分点，构建耗时增长约 1.6 倍，需要按业务权衡。

分片 #3 · 402 token · 与上一片重叠 128 token

索引类型对比：HNSW 适合高召回低延迟场景，IVF 更适合超大规模批量检索，DiskANN 面向磁盘常驻集合。

分片 #4 · 386 token · changelog-2026.txt

量化器以少量召回损失换取存储压缩；RaBitQ 在 1024 维下的压缩率优于 PQ-INT8。

共 128 片 · 平均 448 token · 已丢弃 3 个低于 64 token 的碎片

搜索知识库或文档

用户头像

重置为推荐值

保存并重建索引

嵌入与索引策略 · Embedding

嵌入模型

text-embedding-v4

向量维度 · 类型

1024 · FP32

距离度量 · 归一化

cosine

量化器 · 压缩比

PQ-INT8 · 4×

索引类型

HNSW

IVF

DiskANN

混合检索与预估

稠密向量 semantic

0.70

全文检索 BM25 / n-gram

0.30

预估分片总数

1,024

向量存储（PQ-INT8）

412 MB

预计构建耗时

≈ 42s

保存并重建索引

本地索引占用

412 MB / 2 GB